



**İSTANBUL ÜNİVERSİTESİ-CERRAHPAŞA
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**

**VERİ BİLİMİ FİNAL PROJE RAPORU
AKILLI ŞEHİR & ULAŞIM: METR-LA TRAFİK
VERİ ANALİZİ**

No	Adı	Soyadı
1306230084	Rabianur	Becit

Öğretim Üyesi: Dr. Öğr. Üyesi MUHAMMED ERDEM İSENKUL

Asistan: Araş.Gör. ERSİN ONUR ERDOĞAN

1. PROBLEM TANIMI

Modern kentlerde trafik yönetimi, şehir planlamacıları ve ulaşım otoriteleri için kritik bir sorun olmaya devam etmektedir. Los Angeles, dünyada en yoğun trafiğe sahip şehirler arasında sürekli ilk sıralarda yer almakta; bu durum hem ekonomik kayıplara (yakıt tüketimi, zaman kaybı) hem de çevre sorunlarına (CO₂ emisyonu) yol açmaktadır.

Bu projenin amacı Los Angeles otoyollarındaki anlık hız ve trafik akışını analiz ederek gün içindeki "rush hour" (yoğun saat) örüntülerini ortaya çıkarmak, hafta içi ile hafta sonu arasındaki yoğunluk farklılıklarını incelemektir. Buna ek olarak, sadece zaman bilgisine (saatin kaç olduğuna ve haftanın hangi günü olduğuna) bakarak anlık trafiğin "akıcı" veya "sıkışık" olup olmayacağını tahmin eden makine öğrenmesi tabanlı bir sınıflandırma modeli geliştirmektir.

2. KULLANILAN VERİ SETİ VE KAYNAĞI


Proje kapsamında, akıllı şehir uygulamalarında akademik standart olarak kabul edilen "**METR-LA (Los Angeles Metropolitan Traffic Dataset)**" veri seti kullanılmıştır.

- **Kaynak:** Yaguang Li ve ark. tarafından yayımlanan "*Diffusion Convolutional Recurrent Neural Network*" (ICLR 2018) çalışmasından alınmıştır.
- **İçerik ve Boyut:** Veri seti, Los Angeles otoyol ağındaki 207 farklı döngü dedektöründen (loop detector) alınmış anlık araç hız ölçümlerini içermektedir.
- **Zaman Aralığı ve Format:** 1 Mart 2012 – 27 Haziran 2012 tarihleri arasındaki yaklaşık 4 aylık veriyi kapsar. 5 dakikalık periyotlarla kaydedilmiş, toplamda 34.272 zaman adımı ve 7 milyondan fazla hücre barındıran kompleks bir HDF5 formatındadır. Hız ölçümleri mil/saat (mph) cinsindendir.

3. YÖNTEM

Proje, standart bir veri bilimi iş akışına (CRISP-DM) uygun olarak 3 temel aşamada gerçekleştirilmiştir:

- **Veri Ön İşleme:** HDF5 dosyası düşük seviyeli h5py ve veri işleme kütüphanesi pandas kullanılarak okunmuştur. Veri setindeki eksik veya hatalı sensör okumaları (NaN) tespit edilmiş, zaman serisi bütünlüğünü korumak adına ffill (forward fill) yöntemiyle temizlenmiştir. Ayrıca 0-100 mph dışındaki değerler aykırı değer olarak sorgulanmıştır. Unix formatındaki zaman damgaları, DatetimeIndex formatına çevrilerek içerisinden saat ve haftanın_günü öznitelikleri (feature engineering) türetilmiştir.
- **Keşifsel Veri Analizi (EDA):** Verideki gizli örüntüleri ortaya çıkarmak için Seaborn ve Matplotlib kütüphaneleriyle görselleştirmeler yapılmıştır. Saatlik ortalama hız değişimi (Lineplot), hafta içi/sonu dağılımları (Boxplot), gün-saat matrisi (Heatmap) ve genel hız dağılımı (KDE Histogram) incelenmiştir.




- **Modelleme:** Otoyol hızının 40 mph'nin altına düşmesi "Sıkışık" (1), 40 mph ve üzeri ise "Akıcı" (0) olarak etiketlenip trafik_durumu adında yeni bir hedef değişken üretilmiştir. Eğitim süresini optimize etmek için verinin rastgele %20'si alınarak %80 Eğitim ve %20 Test seti olarak ayrılmıştır. Sınıf dengesizliği problemine karşı class_weight='balanced' parametresi kullanılarak *Random Forest* Sınıflandırıcı modeli kurulmuştur.

4. BULGULAR


Keşifsel veri analizi ve makine öğrenmesi modelinden elde edilen bulgular şunlardır:

- **Günlük Trafik Ritmi:** Açık bir "rush hour" örüntüsü tespit edilmiştir. En yavaş ve yoğun saat **17:00** (ortalama 46.5 mph), en hızlı saat ise gece **03:00** (ortalama 54.7 mph) olarak ölçülmüştür. Akşam trafiği, sabah işe gidiş trafiğine göre çok daha keskin bir yoğunluk yaratmaktadır.




Şekil 2: Günün Saatlerine Göre Ortalama Hız Değişimi

- **Haftalık Farklılıklar:** Hafta sonu trafiği, hafta içine kıyasla ortalama **+2.70 mph** daha hızlı ve akıcıdır. Kutu grafiği analizinde, hafta içi hız dağılımının varyansının çok geniş olduğu (gün içinde otoyolun hem çok boş hem çok kilit olduğu), hafta sonu ise hızın genel olarak istikrarlı ve yüksek kaldığı görülmüştür.




Şekil 3: Hafta İçi ve Hafta Sonu Hız Dağılımlarının Karşılaştırılması

- **Isı Haritası Bulguları:** Perşembe günleri 17:00, Los Angeles trafiğinin en sıkışık olduğu an olarak öne çıkarken; Cumartesi gece 01:00 haftanın en akıcı saatidir.




Şekil 4: Haftanın Günleri ve Saatlara Göre Trafik Yoğunluğu Isı Haritası

- **Model Başarısı:** Kurulan Random Forest modelinde genel doğruluk (Accuracy) %60.8 çıkmıştır. Ancak veri setinin %93'ü "akıcı" sınıfında olduğu için Accuracy metriği yanıltıcıdır. Modelin gerçekte "sıkışık" olan trafik durumlarını bulma oranı (Recall) %58'dir. Saat özneliliğinin tahmine katkısı %54, haftanın günü özneliliğinin katkısı %46'dır.



Şekil 5: Modelin Sınıflandırma Başarısını Gösteren Karmaşıklık Matrisi

- **Sensörler Arası Korelasyon ve Uyum:** Tüm şehir genelindeki trafiğin birbirinden bağımsız mı yoksa birbirine paralel mi aktığını incelemek için rastgele 5 sensörün zaman serisi analizi yapılmıştır.



Şekil 6: Rastgele Seçilen 5 Sensörün 1 Haftalık Hız Değişimi ve Uyumları

Grafik incelendiğinde, farklı lokasyonlardaki sensörlerin hız düşüşlerinin (rush hour saatleri) birbirleriyle oldukça yüksek bir korelasyon (uyum) içinde gerçekleştiği görülmüştür. Bu durum, Los Angeles otoyollarındaki sıkışıklığın bölgesel olmaktan ziyade, tüm şehri eşzamanlı etkileyen genel bir zaman problemi olduğunu kanıtlamaktadır.

5. SINIRLAMALAR

- **Bağlamsal Değişken Eksikliği:** Model yalnızca zaman (saat ve gün) değişkenleri üzerinden tahmin yapmaktadır. Hava durumu, trafik kazaları, yol çalışmaları veya resmi tatiller gibi trafik yoğunluğunu direkt etkileyen harici veri kaynakları analize dahil edilememiştir.
- **Mekansal (Spatial) Analiz Eksikliği:** 207 farklı sensörün verisi genel bir şehir ortalaması olarak kullanılmıştır. Sensörlerin GPS koordinatları veya ağ (graph) yapısı hesaba katılmadığı için, trafiğin hangi bölgede başlayıp hangi yöne doğru tıklandığı gibi mekansal modellemeler yapılamamıştır.
- **Aşırı Dengesiz Sınıf Dağılımı:** Veri setinin %93'ü akıcı, yalnızca %7'si sıkışık trafikten oluşmaktadır. SMOTE gibi sentetik veri çoğaltma teknikleri kullanılmadığı için model çoğunluk sınıfına doğal bir eğilim göstermektedir.

6. ÖĞRENİLENLER

Bu proje süresince hem teknik hem de kavramsal olarak önemli veri bilimi yetkinlikleri kazanılmıştır:

- HDF5 gibi geleneksel CSV'ye göre çok daha karmaşık ve büyük boyutlu veri dosyalarının düşük seviyeli kütüphanelerle (h5py) manipüle edilip kullanıma hazır hale getirilmesi öğrenilmiştir.
- Zaman serisi formatındaki verilerin indeksleri üzerinde manipülasyon yapılarak saf zaman bilgisinden makine öğrenmesi modelleri için anlamlı niteliklerin nasıl türetilceği deneyimlenmiştir.
- Sınıflandırma problemlerinde verinin dengesiz olduğu durumlarda sadece Accuracy (Doğruluk) oranına bakmanın büyük bir yanılgı olduğu; Recall, Precision ve Confusion Matrix okumasının projenin gerçek başarısını gösteren asıl anahtarlar olduğu pratikte ispatlanmıştır.
- Analizlerin sadece kod yazıp grafik çizmekten ibaret olmadığı, her bir grafiğin "Hangi gün daha sıkışık?" gibi gerçek hayat problemlerine somut yanıtlar verecek şekilde hikayeleştirilmesinin önemi kavranmıştır.